

بخش تئوری

.1

Sources in the first group are related to the properties of the MRI device and include static ,eddy currents driven by field gradients ,bandwidth filtering of the data ,field inhomogeneity Sources in .and especially radio frequency (RF) transmission and reception inhomogeneity position and ,i.e., to the shape ,the second group are related to the imaged object itself and to the specific magnetic permeability and ,orientation of the object inside the magnet These intensity inhomogeneities are far more .dielectric properties of the imaged object The impact of the imaged object is rather small in low magnetic field .difficult to deal with and more prominent in high magnetic field MR scanners.

Reference: Vovk, Uro, Franjo Pernus, and Botjan Likar. "A review of methods for correction of intensity inhomogeneity in MRI." IEEE transactions on medical imaging 26.3 (2007): 405-421.

الگوریتم AFCM از تابع هزینه زیر استفاده میکند که ترم اول همان تابع هزینه خوشه بندی FCM است با این تفاوت که در محاسبه فاصله ، مقدار هر پیکسل با ضریبی از مقدار v_k که مرکز خوشه k است انجام میشود تا اثر تغییر روشنایی ناشی از inhomogeneity را خنثی کند و ترم های دوم و سوم m را از طریق جریمه کردن مشتق های اول و دوم آن وادار میکنند که هموار باشد.

$$J_{AFCM} = \sum_{(i,j)} \sum_{k=1}^C u_k^2(i,j) \|y(i,j) - m(i,j)v_k\|_2^2 + \dots$$


$$\lambda_1 \sum_{(i,j)} \left((m(i,j) * D_i)^2 + (m(i,j) * D_j)^2 \right) + \dots$$

$$\lambda_2 \sum_{(i,j)} \left((m(i,j) ** D_{ii})^2 + 2(m(i,j) ** D_{ij})^2 + (m(i,j) ** D_{jj})^2 \right)$$

.2

شبکه Unet، شامل دو بخش encoder و decoder است که اولی ویژگی های تصویر را استخراج میکند و دومی سگمنت های خروجی را بازسازی میکند. این مدل از لایه های کانوولوشن و دیکانولوشنی تشکیل شده و دارای skip connection است که باعث میشود اطلاعات تصویر در لایه های بعدی از بین نرود و دقت را بهتر میکند.

Reference: Ronneberger, Olaf, Philipp Fischer, and Thomas Brox. "U-net: Convolutional networks for biomedical image segmentation." Medical image computing and computer-assisted intervention–MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18. Springer International Publishing, 2015.



3 Training

The input images and their corresponding segmentation maps are used to train the network with the stochastic gradient descent implementation of Caffe [6]. Due to the unpadded convolutions, the output image is smaller than the input by a constant border width. To minimize the overhead and make maximum use of the GPU memory, we favor large input tiles over a large batch size and hence reduce the batch to a single image. Accordingly we use a high momentum (0.99) such that a large number of the previously seen training samples determine the update in the current optimization step.

The energy function is computed by a pixel-wise soft-max over the final feature map combined with the cross entropy loss function. The soft-max is defined as $p_k(\mathbf{x}) = \exp(a_k(\mathbf{x})) / \left(\sum_{k'=1}^K \exp(a_{k'}(\mathbf{x})) \right)$ where $a_k(\mathbf{x})$ denotes the activation in feature channel k at the pixel position $\mathbf{x} \in \Omega$ with $\Omega \subset \mathbb{Z}^2$. K is the number of classes and $p_k(\mathbf{x})$ is the approximated maximum-function. I.e. $p_k(\mathbf{x}) \approx 1$ for the k that has the maximum activation $a_k(\mathbf{x})$ and $p_k(\mathbf{x}) \approx 0$ for all other k . The cross entropy then penalizes at each position the deviation of $p_{\ell(\mathbf{x})}(\mathbf{x})$ from 1 using

$$E = \sum_{\mathbf{x} \in \Omega} w(\mathbf{x}) \log(p_{\ell(\mathbf{x})}(\mathbf{x})) \quad (1)$$

.3

(1

مینای این روش مپ کردن خم ها از دو بعد به سه بعد و حل آن ها است. مزیت این روش non paramteric بودن آن است.

معادله کلی به صورت زیر بیان میشود.

$$\frac{\partial \mathcal{C}(s, t)}{\partial t} = F\mathcal{N}$$

از آنجا که گرادیان فی موازی با بردار عمود بر خم است با جایگذاری به PDE زیر میرسیم.

$$\frac{\partial \phi}{\partial t} = F|\nabla \phi|$$

(2)

تابع انرژی کل از رابطه زیر بدست میاید:

$$\mathcal{E}(\phi) = \mu \mathcal{R}_p(\phi) + \mathcal{E}_{\text{ext}}(\phi)$$

انرژی پتانسیل استفاده شده در مقاله مطابق زیر تعریف میشود:

$$\mathcal{R}_p(\phi) \triangleq \int_{\Omega} p(|\nabla \phi|) d\mathbf{x}$$

تابع پیشنهادی از رابطه زیر بدست می آید که دارای دو نقطه مینیمم با مشتق صفر است و 2 مرتبه مشتق پذیر است.



As mentioned in Section II-A, a preferable potential function p for the distance regularization term \mathcal{R}_p is a double-well potential. Here, we provide a specific construction of the double-well potential $p_2(s)$ as

$$p_2(s) = \begin{cases} \frac{1}{(2\pi)^2}(1 - \cos(2\pi s)), & \text{if } s \leq 1 \\ \frac{1}{2}(s - 1)^2, & \text{if } s \geq 1. \end{cases} \quad (16)$$

بخش عملی

.1


(1) تصاویر ماسک و اولیه را رسم میکنیم.



(2) مقداردهی اویه را انجام می‌دهیم

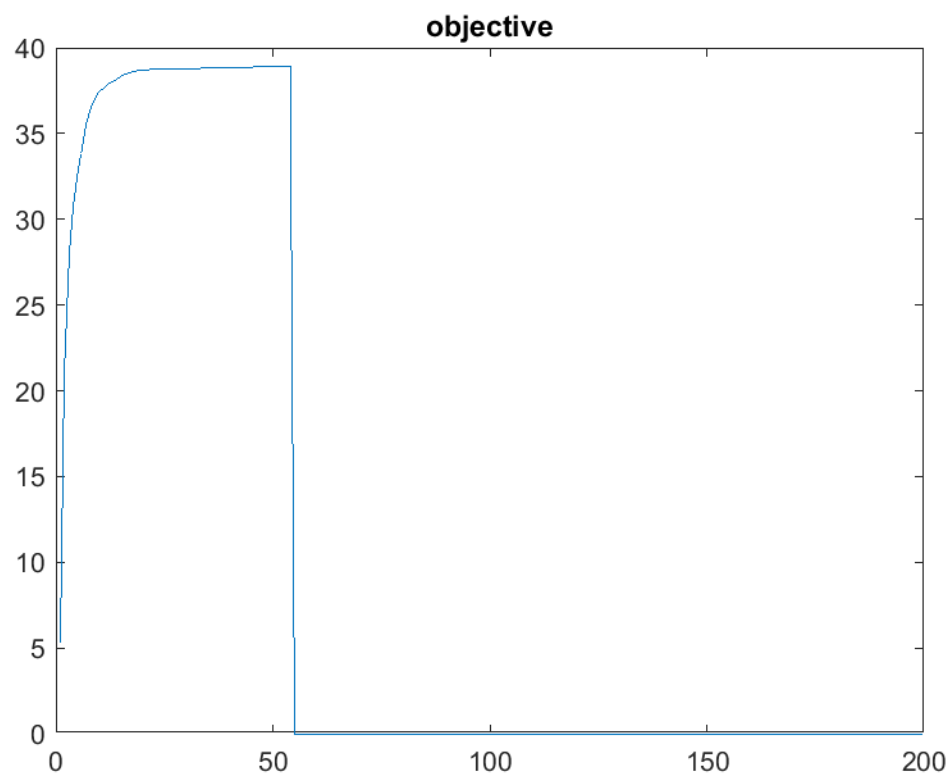
(3)

Initial: K-Means




(4.2

مقدار objective را در iteration های مختلف رسم میکنیم.



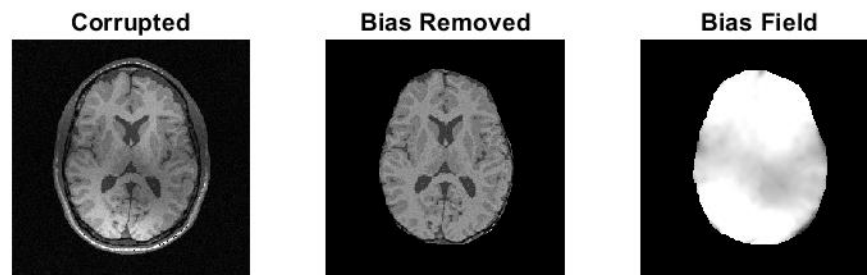
(4.3) میدان بایاس را رسم میکنیم




(4.4

برای حذف بایاس، مقادیر تصویر را بر مقدار میدان در هر پیکسل تقسیم میکنیم.


همانطور که میبینیم الگوریتم BCFCM نتیجه بهتری دارد و به خوبی اثر intensity inhomogeneity را در خوشه بندی حذف کرده و نواحی مغز را به درستی جدا کرده است.



Segmented Image



Initial: K-Means





2.



ابتدا یک کانتور اولیه مستطیلی بیرون جسم ایجاد میکنیم و سپس تصویر را با فیلتر گوسی با واریانس 1 فیلتر میکنیم تا موهای تصویر هموار شوند و کانتور در آنهای گیر نکند. سپس در هر گام زمانی برای هر نقطه از کانتور تفاوت انرژی داخلی و خارجی را هنگامی که نقطه را به یکی از 8 همسایه آن جابجا میکنیم با انرژی داخلی و خارجی در مکان فعلی میسنجیم، در صورتی که با جابجایی انرژی کمتر شود به نقطه جدید میرویم. این کار را برای همه نقاط و برای 50 گام انجام داده و هرگام را در ویدیو ذخیره میکنیم. انرژی خارجی هر نقطه را از روی گرادیان و انرژی داخلی را از روی فاصله با نقطه قبل و بعد آن محاسبه میکنیم. مقدار $\lambda = 50000$.

$$E_{internal} = \sum_{i=1}^n ((x_{i+1} - x_i)^2 - (y_{i+1} - y_i)^2 - \alpha \bar{d})^2$$

$$E_{external} = - \sum_{i=1}^n (G_x^2(x_i, y_i) + G_y^2(x_i, y_i))$$

initial






(2)

به ازای ضرایب فازی مختلف خوشه ها را رسم میکنیم. مشخص است که هرچه این ضریب کمتر باشد همپوشانی سگمنت ها کمتر است و برعکس.

FCM $q = 2$



FCM $q = 5$



FCM $q = 1.1$



(4)

به داده ها مدل GMM با 5 خوه را فیت کرده و با استفاده از واریانس ها و میانگین و احتمال prior، احتمال تعلق هر پیکسل به خوشه ها را بدست میاوریم.

GMM



(5)

برای اینکار ما کسبیم احتمال مربوط به هر خوشه را در نظر میگیریم.


GMM



4.

1) برای مشخص کردن ماسک اولیه توسط کاربر، کاربر 6 نقطه اطراف جسم را با موس انتخاب میکند. سپس نقاط به ورودی roipoly داده میشوند.

melanoma




manual mask - melanoma



contour melanoma




nevus




manual mask - nevus




contour nevus



melanoma




square mask - melanoma



contour melanoma






(2)

در این بخش کاربر 8 نقطه بر روی تصویر انتخاب میکند.

آستانه ماسک را 80 درصد ماکسیمم مقدار روشنایی در نظر میگیریم و با آستانه گذاری، بدون دخالت کاربر ماسک را استخراج میکنیم.


MRI




manual mask - MRI



contour MRI



MRI




square mask - MRI




contour MRI



MRI



threshold mask - MRI



contour MRI

